

LLM 모델 비교·선정 보고서

과업: AI 교육용 강의 설명 및 수업안 초안 자동 생성

작성일: 2026-08-17 (최종본)

1. 비교 목적

동일한 '강의 설명 + 수업안 초안 생성' 과업을 3 종의 LLM(Claude, GPT-4o, Gemini)에 동일 조건으로 입력하여, "느낌"이 아니라 평가 측과 근거에 기반해 실제 업무(사내 AI 교육 콘텐츠 제작)에 가장 적합한 모델을 선정한다.

2. 비교에 사용한 동일 입력 (공통 테스트 프롬프트)

[업무 과업] AI 교육용 강의 설명 및 수업안 초안 자동 생성

[강의 주제] 프롬프트 엔지니어링 기초

[대상 수강생] 비전공 사무직 신입사원 (AI 도구 사용 경험 거의 없음)

[강의 시간] 90 분

[난이도] 입문

[요청 사항] 1) 강의 소개 문구(3~4 문장) 2) 수업안 개요 - 세션 구성(시간 배분 포함), 세션별 학습목표, 실습활동, 평가방법

[형식] 제목 → 소개 → 세션별 목록 순서로, 실무에서 바로 쓸 수 있는 톤

3. 모델·환경 기록 (재현성)

모델명	사용 환경	요금제	사용 날짜	주요 설정	비고
Claude (Sonnet)	웹(anthropic.ai)	유료(Pro) 가정	2026-08-17	temperature 기본값, 별도 조정 없음	본 보고서 내 실제 산출물 기록
GPT-4o	웹(ChatGPT)	(미기재 - 사용자 확인 필요)	2026-08-17	웹 UI 기본 설정	무료/유료 여부 및 제한사항 확인 필요 — 아래 6번 항목 참고
Gemini	웹(Gemini)	무료	2026-08-17	웹 UI 기본 설정	무료 플랜: 컨텍스트 길이 제한, 트래픽 과부하 시 응답 속도 저하 경험

※ GPT-4o 의 요금제·제한사항이 미기재 상태입니다. 실제 사용한 플랜(무료/Plus 등)을 확인해 표를 채워야 재현성 조건이 완성됩니다.

4. 평가 축 및 모델별 점수표 (1~5 점)

평가 축	Claude	근거	GPT-4o	근거	Gemini	근거
정확성/전문성	5	확률적 생성 등 개념 오류 없이 사용	5	환각·Zero/Few-shot 개념까지 정확히 설명, 오류 없음	4	Persona-Context-Format 프레임 등 개념은 정확하나, 환각·사실검증 관련 언급은 없음
구조화/형식 준수	5	요청한 소개문+세션별 목표/활동/평가 모두 포함	5	세션별 학습목표·주요내용·실습·평가 모두 포함 + 전체 시간표·재사용 템플릿까지 추가 제공	3	세션 1~3 에 '평가방법' 항목이 빠져 요청한 4 요소를 세션마다 다 채우지 못함
한국어 자연스러움	4	문장이 매끄러우나 다소 격식체	4	명확하고 매끄러우나 '사수' 등 다소 캐주얼한 표현 일부 사용	4	제목('퇴근을 앞당기는...')과 문체가 매력적이나 실무 톤보다 마케팅 카피에 가까움
실습활동 구체성·실현가능성	4	구체적이나 세션 3 난이도가 대상 수준보다 다소 높음	5	실제 업무(이메일·회의록) 기반 실습 + 수정 전/후 비교까지 포함해 매우 구체적	5	이메일·회의록 등 실무 예시가 구체적이고 실행 가능
재사용성(템플릿화 용이)	4	다른 주제에도 구조 그대로 재사용 가능	5	별도 '업무 프롬프트 템플릿' 섹션 제공으로 재사용성 가장 높음	3	별도 재사용 템플릿 양식은 제공하지 않음

점수 합계

모델	합계(25 점 만점)	순위
GPT-4o	24	1 위
Claude	22	2 위
Gemini	19	3 위

5. 모델별 결과 요약

5.1 Claude

세션 5 개(도입-프롬프트 4 요소-Few-shot/단계적 지시-실전 실습-정리)로 90 분을 배분한 수업안을 생성했다. 세션별 학습목표·활동·평가가 모두 포함되었고 개념 오류는 없었으나, 세션 3(Few-shot/단계적 지시, 25 분)의 실습 난이도가 '비전공 신입사원' 기준으로는 다소 높게 설계되어 조정이 필요했다.

5.2 GPT-4o

세션 4 개(15/20/35/20 분)로 구성했고, 요청한 학습목표·주요내용·실습활동·평가방법을 세션마다 빠짐없이 포함했다. 특히 환각(Hallucination) 개념과 '모르면 확인 필요라고 답하기' 규칙, 그리고 재사용 가능한 '업무 프롬프트 템플릿'까지 요청하지 않은 부분도 스스로 보강해 제공한 점이 인상적이었다. 다만 이 결과물의 구성이 원 과제 지시문의 항목(Zero-shot/Few-shot, 페르소나 등 표현)과 상당히 유사해, 공통 프롬프트 외에

더 많은 맥락이 함께 입력되었을 가능성이 있다 — 공정한 비교를 위해 실제 입력 내용을 다시 확인할 필요가 있다.

5.3 Gemini

세션 4 개(20/40/20/10 분)로 구성했고, 카피라이팅에 가까운 매력적인 제목과 도입부가 특징적이었다. 이메일·회의록 등 실무 예시는 구체적이었으나, 세션 1~3 에는 '평가방법' 항목이 빠져 있어 요청 형식을 완전히 지키지 못했다. 톤 역시 '실무용'보다는 마케팅성 문구에 가까워 요청 취지와 약간 결이 달랐다.

6. 최종 선정 결론

- 본 과업은 '요청 항목 누락 없이 구조화된 결과물'과 '검수 없이 바로 재사용 가능한 템플릿 제공'이 핵심 성공 기준이므로, 구조화/형식 준수·재사용성 축의 가중치를 가장 높게 둔다.
- 점수 합계 기준 GPT-4o(24 점)가 Claude(22 점), Gemini(19 점)보다 높았다. 특히 세션마다 학습목표·활동·평가방법을 누락 없이 채운 형식 준수도와, 환각 방지 규칙·재사용 템플릿을 자발적으로 포함한 완성도에서 차이가 두드러졌다.
- Gemini 는 실습 활동의 실무 적합성은 높았지만 세션별 평가방법 누락으로 형식 준수 점수가 낮아졌고, 톤도 요청한 '실무용'과 다소 어긋났다.
- 따라서 본 강의 설계 과업에는 GPT-4o 를 1 순위로 채택하되, GPT-4o 결과가 원 과제 지시문과 유사한 구조를 보인 점을 감안해 실제 운영 전 '동일 조건 재검증'을 한 차례 거치는 것을 권장한다.